

Yazılım Geliştirme Dersi - 2. Proje

From Black-Box to Explainability: Probabilistic Automata for Time Series Analysis

I. PROJE TANIMI VE MOTIVASYON

Zaman serisi verileri; finansal sistemler, biyomedikal sinyaller, IoT altyapıları ve davranışsal analiz uygulamaları gibi birçok alanda yaygın olarak kullanılmaktadır. Bu tür veriler üzerinde gerçekleştirilen sınıflandırma ve anomali tespiti problemleri, hem akademik araştırmalar hem de endüstriyel uygulamalar açısından kritik öneme sahiptir.

Bu proje kapsamında, zaman serisi verileri üzerinde iki farklı modelleme paradigmasının karşılaştırılması hedeflenmektedir:

- Derin öğrenme tabanlı, yüksek doğruluk potansiyeline sahip ancak yorumlanabilirliği sınırlı olan black-box modeller
- Sembolik temsil ve durum geçişlerine dayalı, yorumlanabilir (interpretable) otomata tabanlı modeller

Proje, modellerin yalnızca performans açısından değil; aynı zamanda genellenebilirlik, gürültüye dayanıklılık ve açıklanabilirlik gibi kriterler çerçevesinde analiz edilmesini amaçlamaktadır.

II. ARAŞTIRMA PROBLEMİ VE AMAÇ

Bu çalışmada aşağıdaki temel araştırma problemi ele alınmaktadır:

Farklı modelleme yaklaşımları, zaman serisi verileri üzerinde farklı veri koşulları altında nasıl davranmaktadır ve bu davranışlar istatistiksel olarak anlamlı mıdır?

Bu kapsamda proje aşağıdaki hedefleri içermektedir:

- Farklı modelleme yaklaşımlarının karşılaştırmalı analizi
- Model performansının veri setine bağımlılığının incelenmesi
- Gürültü ve bilinmeyen veri durumlarında model davranışının değerlendirilmesi
- Açıklanabilirlik açısından modellerin analiz edilmesi

III. VERİ SETİ SEÇİMİ VE KULLANIMI

Bu proje kapsamında tüm veri setleri anomali tespiti problemi olarak ele alınacaktır. Her grup iki farklı veri seti üzerinde çalışacaktır:

- **SKAB**
- **BATADAL**

A. SKAB Veri Setinin Kullanımı

SKAB veri seti için yalnızca `valve1` ve `valve2` klasörleri kullanılacaktır. Öğrenciler bu iki klasörde yer alan tüm `.csv`

dosyalarını `concat` işlemi ile birleştirerek tek bir veri seti oluşturmalıdır.

Birleştirme sırasında aşağıdaki ek sütunlar oluşturulmalıdır:

- `source_group`: Kaydın `valve1` veya `valve2` klasöründen geldiğini gösterir.
- `source_file`: Kaydın hangi `.csv` dosyasından geldiğini gösterir.

Bu ek sütunlar model girdisi olarak kullanılmayacaktır. Yalnızca veri takibi, dosya bazlı veri bölme ve sonuç analizi amacıyla kullanılacaktır.

SKAB veri setinde hedef değişken `anomaly` sütunudur. Model girdisi olarak yalnızca sensör değişkenleri kullanılmalıdır. `datetime`, `changepoint`, `source_group` ve `source_file` sütunları model girdisine dahil edilmemelidir.

B. BATADAL Veri Setinin Kullanımı

BATADAL veri seti için yalnızca `Training Dataset 2` kullanılacaktır. Öğrenciler bu veri setinde yer alan sensör ve sistem değişkenlerini model girdisi olarak kullanmalı, saldırı/anomali bilgisini gösteren etiket sütununu ise hedef değişken olarak ele almalıdır. Etiket sütununun adı veri dosyası üzerinde kontrol edilmeli ve raporda açıkça belirtilmelidir.

`Training Dataset 1` yalnızca normal operasyon verisi içerdiği için bu proje kapsamında zorunlu supervised sınıflandırma verisi olarak kullanılmayacaktır. `Test Dataset` ise etiket bilgisi içermediği için model performansının değerlendirilmesinde kullanılmayacaktır.

BATADAL veri setinde zaman bilgisini içeren sütunlar doğrudan model girdisi olarak kullanılmamalıdır. Bu sütunlar yalnızca zaman sırasının korunması, veri bölme ve sonuçların zamansal olarak yorumlanması amacıyla kullanılmalıdır.

IV. VERİ ÖN İŞLEME

Veri ön işleme süreci aşağıdaki adımları içermelidir:

- Veri normalizasyonu
- Gerekli durumlarda eksik veri işlemleri
- Çok değişkenli veri için boyut indirgeme (PCA)

Otomata tabanlı model yalnızca tek boyutlu veri ile çalıştığı için, çok değişkenli veri setlerinde tüm özellikler PCA ile tek boyuta indirgenmeli ve ilk bileşen (PC1) kullanılmalıdır.

V. MODELLEME YAKLAŞIMLARI

A. Derin Öğrenme Modeli

Öğrenciler aşağıdaki modellerden en az ikisini uygulamalıdır:

- LSTM
- GRU
- 1D-CNN

Model eğitimi, doğrulama ve test süreçleri açık bir şekilde raporlanmalıdır.

B. Otomata Tabanlı Model

Otomata modeli aşağıdaki dönüşümler üzerinden inşa edilecektir:

- PAA (Piecewise Aggregate Approximation)
- SAX (Symbolic Aggregate approXimation)
- Sliding Window ile örüntü (pattern) çıkarımı

Her benzersiz pattern bir durum (state) olarak tanımlanır ve durumlar arası geçiş olasılıkları hesaplanır.

VI. UNSEEN PATTERN YÖNETİMİ

Test aşamasında daha önce gözlemlenmemiş örüntüler ile karşılaşılması durumunda:

- Levenshtein (Edit Distance) algoritması uygulanmalıdır
- En yakın pattern belirlenerek sistem bu state üzerinden devam etmelidir

Bu mekanizmanın birim testlerle doğrulanması zorunludur.

A. Unseen Veri Senaryosunun Tanımlanması

Unseen veri aşağıdaki yöntem ile oluşturulmalıdır.

- Eğitim verisinden elde edilen SAX sözlüğü çıkarılır
- Test sırasında sözlükte bulunmayan pattern'lar unseen olarak kabul edilir

VII. DENEYSEL TASARIM

Deneyler üç farklı senaryo altında yürütülmelidir:

- Orijinal veri
- Gürültü eklenmiş veri (Gaussian noise)
- Unseen veri

A. Parametre Analizi

İki aşamalı bir deney tasarımı uygulanacaktır:

a- Sabit parametreler (karşılaştırma için):

- window size = 4
- alphabet size = 3

b- Parametre varyasyonu:

- window size: 3, 4, 5, 6
- alphabet size: 3, 4, 5, 6

Parametre değişimlerinin:

- Model performansı
- State sayısı
- Geçiş yoğunluğu

üzerindeki etkileri analiz edilmelidir.

B. Standart Deney Protokolü (Zorunlu)

Tüm gruplar için deneylerin karşılaştırılabilir olması amacıyla veri bölme stratejisi veri setinin yapısına uygun şekilde uygulanmalıdır. Satır bazlı rastgele bölme, zaman serisi bağımlılığını ve deney bütünlüğünü bozabileceği için kullanılmamalıdır.

SKAB veri seti için:

- source_file sütunu grup değişkeni olarak kullanılmalıdır.
- Aynı .csv dosyasına ait kayıtlar hem eğitim hem de test kümesinde aynı anda yer almamalıdır.
- GroupKFold veya mümkünse StratifiedGroupKFold uygulanmalıdır.
- Sonuçlar fold ortalaması ve standart sapması ile raporlanmalıdır.

BATADAL veri seti için:

- Zaman sırası korunmalıdır.
- Rastgele satır bazlı bölme yapılmamalıdır.
- Veri zaman sırasına göre %60 eğitim, %20 doğrulama ve %20 test olarak ayrılmalıdır.
- Farklı oran kullanımı kabul edilmez.

Veri sızıntısı (data leakage) önleme kuralları:

- Normalizasyon yalnızca **train** verisi üzerinde fit edilmelidir.
- Aynı dönüşüm validation ve test verisine uygulanmalıdır.
- PCA yalnızca **train** verisi üzerinde fit edilmelidir.
- SAX/PAA sözlüğü ve otomata geçiş olasılıkları yalnızca **train** verisi kullanılarak oluşturulmalıdır.

Model eğitim parametreleri (tüm modeller için sabit):

- Epoch üst sınırı: 50
- Batch size: 32
- Early stopping: validation loss (patience = 5)
- Random seed: 42, 123, 2026, 7, 999

VIII. YAZILIM MIMARISI VE TASARIM GEREKSİNİMLERİ

Proje, parametrik ve modüler bir yazılım mimarisi ile geliştirilmelidir.

Aşağıdaki gereksinimler zorunludur:

- Tüm parametreler merkezi bir konfigürasyon yapısında tutulmalıdır
- Veri işleme ve modelleme süreçleri pipeline yapısı ile tasarlanmalıdır
- Parametre değişiklikleri sistemin tamamını otomatik olarak yeniden oluşturmalıdır

Hard-coded değer kullanımı kabul edilmemektedir.

A. Deney Takibi ve Loglama

- Her deneyin parametreleri kaydedilmelidir
- Performans metrikleri otomatik loglanmalıdır
- Deney sonuçları karşılaştırılabilir formatta saklanmalıdır

IX. DEĞERLENDİRME METRİKLERİ VE İSTATİSTİKSEL ANALİZ

Model performansı aşağıdaki metriklerle değerlendirilmelidir:

- Accuracy
- Precision
- Recall
- F1-score

Değerlendirme stratejisi veri setine uygun şekilde uygulanmalıdır:

- SKAB veri seti için dosya bazlı GroupKFold veya StratifiedGroupKFold kullanılmalıdır.
- BATADAL veri seti için zaman sıralı %60 eğitim, %20 doğrulama ve %20 test ayrımı kullanılmalıdır.
- Uygun durumlarda Wilcoxon veya McNemar testi uygulanarak model farklarının istatistiksel anlamlılığı tartışılmalıdır.

A. Deney Tekrarı ve İstatistiksel Güvenilirlik

- Her deney 5 farklı random seed [42, 123, 2026, 7, 999] ile çalıştırılmalıdır.
- Sonuçlar ortalama ve standart sapma olarak raporlanmalıdır.
- SKAB için fold bazlı sonuçlar ayrıca verilmelidir.
- BATADAL için zaman sıralı test kümesi üzerindeki sonuçlar ayrı raporlanmalıdır.

X. OLASILIKSAL AÇIKLANABİLİRLİK MODÜLÜ

Bu projede geliştirilen açıklanabilirlik modülü, doğrudan **olasılıksal otomata modelinin** iç yapısına dayalı olarak tasarlanmıştır.

Amaç, modelin yalnızca tahmin üretmesi değil, aynı zamanda karar sürecinin **olasılıksal geçişler üzerinden matematiksel olarak gerekçelendirilmesidir**.

A. Temel Gereksinimler (Zorunlu)

Açıklanabilirlik modülü her karar için aşağıdaki bilgileri üretmelidir:

- Mevcut durum (state)
- Gözlemlenen örüntü (pattern)
- Örüntünün eğitim verisinde bulunup bulunmadığı
- Unseen durumunda uygulanan eşleme mekanizması
- Gerçekleşen durum geçişleri (state transitions)
- Her geçişin olasılığı
- Gözlemlenen örüntü dizisinin toplam olasılığı (path probability)

- Nihai karar ve bu kararın olasılıksal gerekçesi

Bu açıklamalar deterministik, yeniden üretilebilir ve modelin iç hesaplamaları ile tutarlı olmalıdır.

B. Güven Skoru

Modelin verdiği her karar için bir **güven skoru** hesaplanmalıdır. Bu skor, otomata üzerindeki geçiş olasılıkları kullanılarak elde edilmelidir.

C. Geçiş Olasılıklarının Hesaplanması

Olasılıksal otomata modeli, durumlar arası geçiş olasılıklarını frekans tabanlı olarak öğrenir:

$$P(S_i \rightarrow S_j) = \frac{\text{Geçiş Sayısı}}{\text{Toplam Çıkış Sayısı}}$$

Bir örüntü dizisinin olasılığı, ardışık geçiş olasılıklarının çarpımı ile hesaplanır:

$$P(\text{sequence}) = \prod P(S_i \rightarrow S_{i+1})$$

Düşük olasılığa sahip diziler, model tarafından beklenmeyen davranışlar olarak değerlendirilir ve anomali adayı olarak işaretlenir.

Yorumlama:

- Düşük olasılık $\rightarrow$ Anomali olasılığı yüksek
- Yüksek olasılık $\rightarrow$ Normal davranış

D. Opsiyonel Gelişmiş Analizler

Aşağıdaki yöntemler ek puan kapsamında değerlendirilecektir:

- **Benzerlik Tabanlı Açıklama:** Unseen pattern'ların en yakın pattern'lara olan mesafelerinin raporlanması
- **Karşıt Durum Analizi (Counterfactual):** Alternatif pattern'lar altında model çıktısının nasıl değişeceğinin analiz edilmesi

E. Örnek Açıklama

[SYSTEM DECISION]

Time Step: t = 5
Previous State: "aab"

Incoming Pattern: "adc"
Status: Unseen

Nearest Pattern: "abc" (distance = 1)

Transitions:
aab $\rightarrow$ abc : 0.72
abc $\rightarrow$ bcc : 0.15

Path Probability:
 $0.72 * 0.15 = 0.108$

Decision:
 Low probability path detected

Result: ANOMALY
 Confidence Score: 0.108 (Low)

F. Çıktı Formatı (Zorunlu)

Model çıktıları aşağıdaki formatlardan biri ile sunulmalıdır:

JSON formatı:

```
{
  "time_step": 5,
  "state": "aab",
  "pattern": "adc",
  "status": "unseen",
  "mapped_to": "abc",
  "probability": 0.108,
  "decision": "anomaly"
}
```

veya tablo formatında raporlanmalıdır.

XI. RAPORLAMA VE BEKLENTİLER

Rapor aşağıdaki analizleri içermelidir. GitHub üzerinde readme.md dosyasında Markdown kullanılarak yazılmalıdır.

- Model karşılaştırmaları
- Veri setleri arası performans farkları
- Gürültü etkisi analizi
- Unseen veri davranışı
- Parametre etkileri

Bu proje kapsamında amaç, tek bir en iyi modeli belirlemekten ziyade, model davranışlarını bilimsel ve sistematik bir şekilde analiz etmektir.

Rapor aşağıdaki görselleri içermelidir:

- Confusion Matrix
- ROC veya Precision-Recall eğrisi (uygunsa)
- Automata state diagram
- Transition probability heatmap
- Parametre duyarlılık grafikleri

XII. TARİHLER

Proje süreçlerine ait takvim aşağıda belirtilmiştir:

Proje Son Teslim Tarihi: 7 Haziran 2026 Pazar, Saat 23.59

Proje Sunum Tarihleri: 8-12 Haziran 2026 tarihleri arasında yapılacaktır. (Son teslim tarihinden sonra sunum listeleri ilan edilecektir.)

Önemli Notlar ve İhlal Durumları:

- Kopya çektiği/intihal yaptığı tespit edilen projeler **0 (sıfır)** olarak notlandırılacaktır.
- GitHub'a düzenli ve ekip üyesi sayısına göre orantılı commit yapmayanlar **0 (sıfır)** olarak notlandırılacaktır.
- Belirtilen tarihe kadar grup oluşturmayan, ekip arkadaşı olmasa dahi listeye ismini eklemeyen, proje dosyalarının gönderimini sağlamayan öğrenciler ve projeler **0 (sıfır)** olarak notlandırılacaktır.
- Her grup yalnızca tek ve ortak bir proje geliştirip sunacaktır. Ayrı ayrı sunum alınmayacak olup ekibin tamamı **0 (sıfır)** olarak notlandırılacaktır.

Tablo I
DEĞERLENDİRME KRİTERLERİ (RUBRİK)

Değerlendirme Kriteri	Puan
1. Yazılım Mimarisi ve Kod Kalitesi - Merkezi konfigürasyon yapısı ve parametre bağımlı otomatik model üretimi (8 Puan) - Modüler pipeline mimarisi (veri akışı + model entegrasyonu) (7 Puan) - Kod kalitesi, isimlendirme, Git kullanımı ve proje organizasyonu (5 Puan)	20
2. Veri Ön İşleme ve Modelleme Doğruluğu - İki veri seti için doğru ön işleme (normalizasyon, PCA vb.) (5 Puan) - Derin öğrenme modelinin doğru kurulumu ve eğitimi (5 Puan) - Otomata modelinin doğru inşası (PAA, SAX, sliding window) (5 Puan) - Geçiş olasılıklarının doğru hesaplanması ve gerekirse smoothing uygulanması (5 Puan) - Unseen veri yönetimi (Levenshtein) ve buna ait birim testler (5 Puan)	25
3. Olasılıksal Açıklanabilirlik Modülü - State, pattern, transition ve unseen mekanizmasının doğru raporlanması (5 Puan) - Geçiş olasılıklarının açık şekilde sunulması (5 Puan) - Path probability (veya eşdeğeri) hesaplanması (5 Puan) - Güven skorunun (confidence) doğru tanımlanması ve yorumlanması (5 Puan)	20
4. Deneysel Tasarım ve İstatistiksel Analiz - Farklı senaryoların (normal, gürültü, unseen) sistematik olarak test edilmesi (5 Puan) - Parametre etkisinin (window size, alphabet size) analiz edilmesi (5 Puan) - Veri setine uygun değerlendirme stratejisinin (SKAB için GroupKFold, BATADAL için zaman sıralı değerlendirme) ve istatistiksel testlerin doğru uygulanması (5 Puan)	15
5. Akademik Raporlama ve Analitik Derinlik - Veri setleri arası karşılaştırmalı analiz ve model davranışı yorumlama (8 Puan) - Olasılıksal sonuçların (low/high likelihood) doğru yorumlanması (5 Puan) - Görselleştirme (automata grafikleri, performans tabloları) (3 Puan) - Akademik yazım, yapı ve kaynak kullanımı (4 Puan)	20
TOPLAM	100